PROCESO ETL

Omar Armando Neira Ordoñez (20192020110)

María Fernanda Pérez Hernández (20211020002)

Andres Felipe Morera Diaz (20191020056)

Jonathan Estiven Castellanos Castellanos (20191020003)

Septiembre de 2024.

Universidad Distrital Francisco José de Caldas
Facultad de Ingeniería
Tendencias Avanzadas de Ingeniería de Software

Índice general

3
4
4
4
5
5
5
5
5
6
6
6
6
6
7
7
8
8
12
12
14
15
20

Índice de figuras

Figura 1. Diseño del Datawarehouse general	8
Figura 2. Boceto del Datawarehouse para pregunta 1	9
Figura 3. Boceto del Datawarehouse para pregunta 2.	10
Figura 4. Boceto del Datawarehouse para pregunta 3	10
Figura 5. Boceto del Datawarehouse para pregunta 4	11
Figura 6. Boceto del Datawarehouse para pregunta 5	11
Figura 7. Muestra de configuración de ML Devs	12
Figura 8. Muestra de aplicación de permisos ML Devs	13
Figura 9. Muestra de aplicación de data de ML Devs	13
Figura 10. Muestra de código fuente frontpage categoría portátiles	14
Figura 11. Muestra de tabla de productos en postgresQL	15
Figura 12. Muestra de tabla de gráfico pregunta 1	16
Figura 14. Muestra de tabla de gráfico pregunta 2 parte 1	16
Figura 15. Muestra de tabla de gráfico pregunta 2 parte 2	17
Figura 16. Muestra de tabla de gráfico pregunta 3	17
Figura 16. Muestra de tabla de gráfico pregunta 4	17
Figura 16. Muestra de tabla de gráfico pregunta 5	18

Proceso ETL

El proceso ETL que se llevará a cabo será a partir de la empresa "Mercadolibre", la cual quiere tiene como misión "Democratizamos el comercio y los servicios financieros para transformar la vida de millones de personas en América Latina." (Mercado Libre, 2024) y se busca hacer una recolección de datos de diferentes fuentes, para poder crear un repositorio llamado "data warehouse", en el cual luego de una serie de filtros, limpieza y análisis de los datos en bruto se podrá generar dashboards partiendo de unas preguntas orientadoras, que ayudarán a la toma de decisiones administrativas.

Mercado Libre API

Mercado libre al generar publicaciones de artículos también propone "sistemas que gestionen búsquedas, preguntas y respuestas, manejar inventario, variaciones del mismo producto, gestionar ventas, envío y calificaciones", como lo es su API, más específicamente la del market ya que también cuenta con la de mercado pago, mercado envios y mercado shops, esta API nos ayudará a tener información de primera mano de Mercado Libre.

Tendencias

Según mercado libre la API maneja las tendencias así, "Las búsquedas que más crecieron están calculadas en las últimas dos semanas. (Se realiza una comparación de ambas semanas), Las búsquedas más deseadas y más populares son el resultado de la última semana. Esta información es renovada semanalmente." así que será clave reconocer en qué momento se hará la búsqueda de las tendencias para la creación de los informes.

Dominios y categorías

Según el API Docs sirve "para trabajar con las opciones del árbol de categorías y listas de Mercado Libre", así que podremos conocer información filtrada por categorías, dando más orden y precisión a los datos recolectados.

Envíos

Gracias a esta parte de la API podemos conocer todo lo necesario frente a los envíos y por ejemplo con el recurso "/shipments/shipment_id/costs" podemos ver el costo que el usuario debe afrontar por un envío.

Búsqueda de ítems

La búsqueda de ítems permite reconocer de forma más específica cada artículo dentro de Mercado Libre, dándonos la libertad de conocer información específica de cada uno, ya sea los vendedores que lo ofrecen, por categorías, por su nickname, etc.

WebScrapping

Por medio de este sistema se tiene acceso a información según los estándares definidos para el scrapper, cómo por ejemplo los es la comparación de precios, investigación del mercado, monitoreo de publicaciones y novedades, análisis de sentimientos y valor de sentimiento asociado a un producto, existen herramientas populares para desarrollar este sistema cómo lo es BeautifulSoup.

Comparación de precios

Se comparan los precios de los productos entre diferentes vendedores.

Novedades

Información sobre las actualizaciones y nuevos productos disponibles en Mercado Libre.

Herramientas

Las herramientas que posibilitan esta recolección y pueden ser utilizadas en este proyecto, recolectan información y a través de diferentes métodos podremos filtrar la información para interpretarla y utilizarla.

BeautifulSoup

Es una librería de Python diseñada para "screen - scrapping", donde provee métodos para extraer información de documentos que se le ofrezcan sin necesidad de utilizar muchas líneas de código, este software ha sido utilizado en muchos proyectos, como lo fue en la lucha del COVID ya que ayudaba a los investigadores a seguirle el rastro a el esparcimiento del virus.

Bokeh

Es una librería de Python de código abierto, diseñada para generar visualizaciones interactivas de gráficas de datos, esta es bastante flexible ya que se pueden crear gráficos desde los más básicos hasta gráficos muy elaborados o especializados dependiendo de las necesidades del usuario.

Pandas

Es una librería de Python de código abierto, diseñada para análisis y manipulación de datos, esta es rápida, poderosa y flexible, es una herramienta que se eligió dado la gran compatibilidad que tiene con la anteriormente mencionada Bokeh.

Fuentes

Las siguiente fuente se propone a partir del valor que pueden dar a la alimentación de información para los datawarehouse, se tuvo en un primer instante en cuenta múltiples fuentes que no fueron posibles de recolectar, ya que pueden evitaban o tenían prohibido la recolección de información de sus plataformas a través del web scraping.

Mercado Libre

Utilizando el scrapping directo en las publicaciones de mercado libre se puede conocer mucha de la información de los productos como calificaciones, imágenes de productos, etc. entonces se podrá conocer de primera mano la información y se podrá filtrar para la creación de dashboards fieles a la realidad del negocio. Esto a partir del uso de las fuentes que ellos mismos proveen y de sus front-pages.

Interrogantes

Las siguientes interrogantes se proponen para la creación de un dashboard (interfaz de usuario)

- 1. ¿Cuáles son las tiendas con mayores ventas y mejores categorías de vendedor, cuáles son sus productos con más unidades disponibles en la categoría de computación?
 - a. Se dará respuesta a esta interrogante utilizando los datos: productos (name, category, available quantity, price, shop_id, shop_name en la API), tiendas (shop_id, shop_name, la categoría de vendedor o power_seller_status y total_transactions en la API), categorías (name e id en la API).
- 2. ¿Qué porcentaje de productos (top 5) ofrece envío gratis por categoría (tecnología)?
 - a. Se dará respuesta a esta interrogante utilizando los datos: productos (scrapping con python de front page), búsqueda por ítems de manera manual.

- 3. ¿Cuáles son los rangos de precios más frecuentes para laptops, agrupados por marca (5 marcas más caras)?
 - a. Se dará respuesta a esta interrogante utilizando los datos: productos (name, category, price, brand en la API), categorías (name e id en la API).
- 4. ¿Qué productos en la categoría deportes tienen el mayor precio y stock disponible?
 - a. Se dará respuesta a esta interrogante utilizando los datos: productos (name, category, available quantity, price en la API), categorías (name e id en la API).
- 5. ¿Cuáles son los 3 productos reacondicionados con más calificaciones en la categoría de electrodomésticos?
 - a. Se dará respuesta a esta interrogante utilizando los datos: productos (scrapping con python de front page), búsqueda por ítems de manera manual.

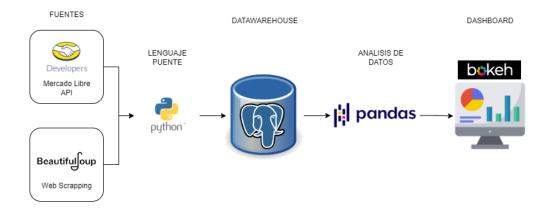
Data Warehouse

Se propone un data warehouse general para cargar la información relevante que recolectamos, con el fin de armar reportes y potenciales tomas de decisiones de mercado libre. También se proponen diferentes datawarehouse que logran englobar la información requerida para dar sustento y solucionar las preguntas guías, este datawarehouse residirá en la herramienta de bases de datos PostgresQL.

Data warehouses

Figura 1. Diseño del Datawarehouse general

Diseño del Datawarehouse. Elaboración propia de los autores.



El Data Warehouse estructurará los datos recolectados para facilitar el análisis:

• Dimensiones:

- o **Productos**: Nombre, categoría, precio, stock, tipo de envío.
- Vendedores: Calificación y número de ventas.
- o **Tiempo**: Día, semana, mes.

• Hechos:

- Ventas: Registro de las ventas, enlazadas a productos, vendedores y tiempo.
- o Envíos: Detalles de los envíos, costos y si ofrecieron envío gratuito.

Figura 2. Boceto del Datawarehouse para pregunta 1

Boceto del Datawarehouse, pregunta 1. Elaboración propia de los autores.

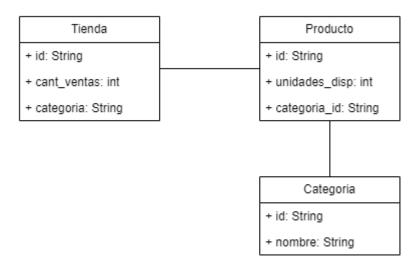


Figura 3. Boceto del Datawarehouse para pregunta 2

Boceto del Datawarehouse, pregunta 2. Elaboración propia de los autores.

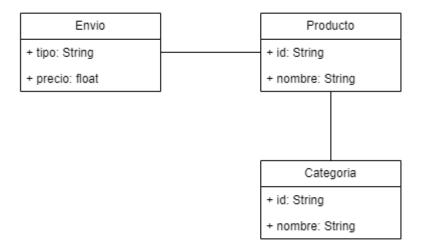


Figura 4. Boceto del Datawarehouse para pregunta 3

Boceto del Datawarehouse, pregunta 3. Elaboración propia de los autores.

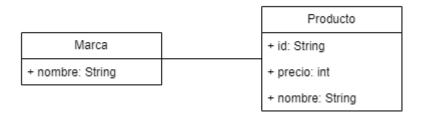


Figura 5. Boceto del Datawarehouse para pregunta 4

Boceto del Datawarehouse, pregunta 4. Elaboración propia de los autores.

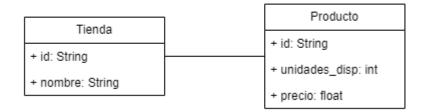
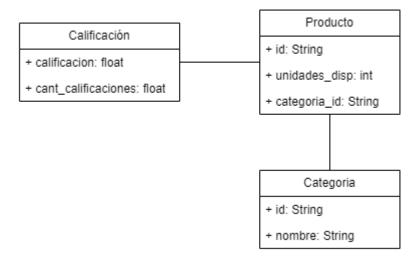


Figura 6. Boceto del Datawarehouse para pregunta 5

Boceto del Datawarehouse, pregunta 5. Elaboración propia de los autores.



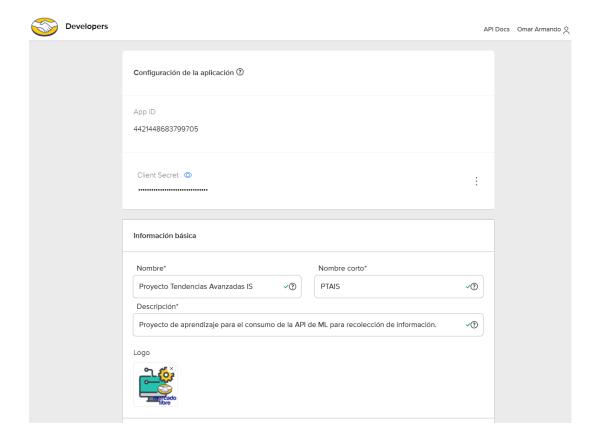
Desarrollo

Mercado Libre API

Para la toma de datos de mercado libre se utilizo la documentacion disponible en "https://developers.mercadolibre.cl/es_ar/guia-para-producto", donde como primero teniendo una cuenta de mercado libre se verifico la informacion personal del usuario incluyendo documentos de identificacion; luego dentro de mercado libre devs se creo una aplicacion de mercado libre llamada "Proyecto Tendencias Avanzadas IS", la cual se configuro con todos los tipos de busqueda disponibles y que tiene la siguiente información:

Figura 7. Muestra de configuración de ML Devs

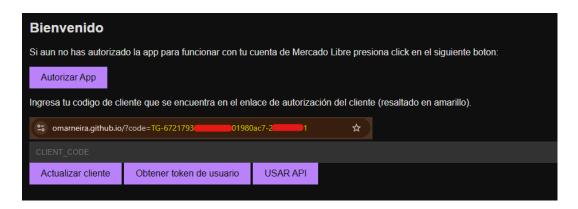
Muestra de configuración de ML Devs. Elaboración propia de los autores.



Luego de esto teniendo la APP ID y el cliente secreto se utilizó aplicaciones creadas por los autores para poder comunicarse con la API, primero una app para autorizar la aplicación para hacer peticiones a nombre de la cuenta que de permisos:

Figura 8. Muestra de aplicación de permisos ML Devs

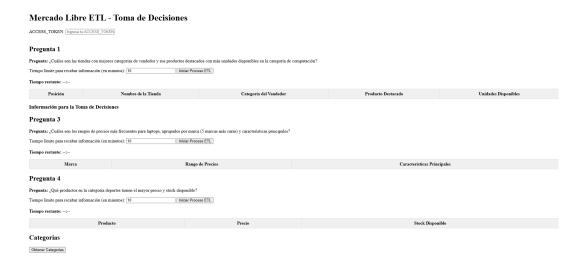
Muestra de aplicación de permisos ML Devs. Elaboración propia de los autores.



Luego se creó otra app aparte utilizando el token de usuario que da la aplicación para poder comunicarse, visualizar y guardar la información en crudo:

Figura 9. Muestra de aplicación de data de ML Devs

Muestra de aplicación de data de ML Devs. Elaboración propia de los autores.



Esta aplicación se le da un tiempo limite para hacer peticiones que ira haciendo cada cierto tiempo para no violar el maximo de peticiones por minuto, sin embargo, ML API tiene

un limite de recoleccion de informacion de 1000 paginas, todo esto es almacenado en archivos JSON en local que posteriormente seran utilizados.

Web scraping (Beautiful Soup)

Originalmente en el apartado de web scraping se pensó en generar modelos automatizados que se encargaran de conectarse al front-page de ML para hacer recolección por ahí, sin embargo, las políticas de ML y la seguridad del mismo evitan esto, por lo tanto, se hizo una extracción manual a partir de la búsqueda de los front-page que más funcionan para su análisis de datos y se descargo el código fuente html de la página de la siguiente manera:

Figura 10. Muestra de código fuente frontpage categoría portátiles

Muestra de código fuente frontpage categoría portátiles. Elaboración propia de los autores.

```
| Company | Part | Part
```

Esto se aplicó a múltiples front-page y se utilizo python con beautifulsoup para hacer el scraping pero "offline" con los archivos html resultantes, aquí se analizó la estructura del frontpage de mercado libre, de esta manera se le pudo indicar a beautifulsoup donde se

encontraba la información y cómo podría recabarla usando filtros como find.all.

Posteriormente se guardó la información recabada en archivos JSON.

Dashboard

Para la elaboración del dashboard primero se elaboró el datawarehouse, este se encuentra localizado en la herramienta postgresQL, y se hizo la conexión y automatización de subida de datos utilizando la librería de Python "psycop2", aunque primero se hizo la respectiva recolección de los JSON en crudo que conseguimos de las diferentes fuentes para filtrar con la librería "Pandas" creando múltiples dataframes que serían posteriormente unificados para subirlos a las tablas producto, tienda y categorías.

Figura 11. Muestra de tabla de productos en postgresQL

Muestra de tabla de productos en postgresQL. Elaboración propia de los autores.



Ya teniendo la información depurada y subida al data frame se utiliza los cursores que provee "psycop2" para recoger la información, dependiendo la pregunta se recogió diferentes columnas de las múltiples tablas que se generaron, esto basados en los diseños de cada pregunta trozo de data warehouse, utilizando pandas ordenamos, filtramos, agrupamos la información según sea necesario y luego pasamos a la herramienta "Bokeh" para poder mostrar la información, dándonos como resultados las siguientes gráficas.

Figura 12. Muestra de tabla de gráfico pregunta 1

Muestra de gráfico pregunta 1. Elaboración propia de los autores.

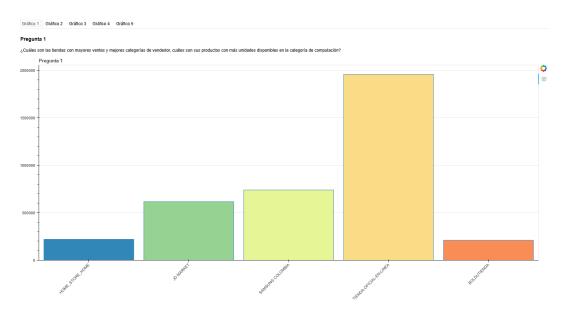


Figura 14. Muestra de tabla de gráfico pregunta 2 parte 1

Muestra de gráfico pregunta 2 parte 1. Elaboración propia de los autores.

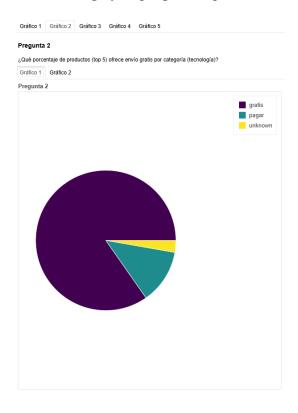


Figura 15. Muestra de tabla de gráfico pregunta 2 parte 2

Muestra de gráfico pregunta 2 parte 2. Elaboración propia de los autores.

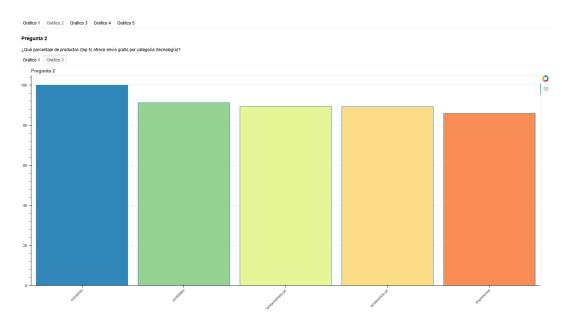


Figura 16. Muestra de tabla de gráfico pregunta 3

Muestra de gráfico pregunta 3. Elaboración propia de los autores.

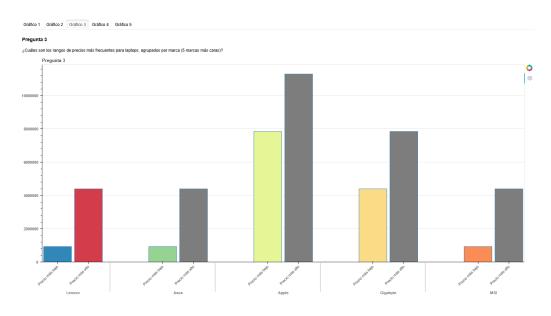


Figura 16. Muestra de tabla de gráfico pregunta 4

Muestra de gráfico pregunta 4. Elaboración propia de los autores.

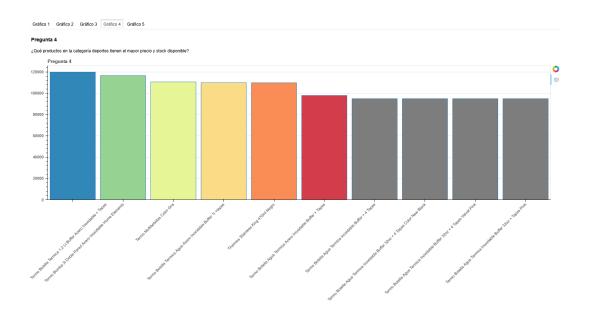
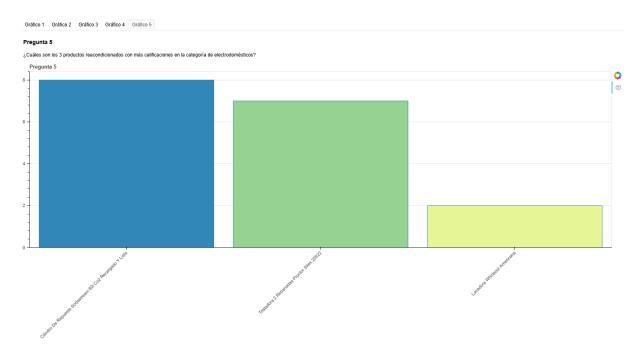


Figura 16. Muestra de tabla de gráfico pregunta 5

Muestra de gráfico pregunta 5. Elaboración propia de los autores.



Conclusiones

El uso de filtros, limpieza y análisis de los datos en bruto para la generación de dashboards es una poderosa herramienta para la toma de decisiones empresariales, partiendo de unas preguntas orientadoras y basados en información que está disponible para todo el

mundo, se puede dar una guia a organizaciones y a sus procesos ya que dependiendo de lo que logren recabar de la información pueden llegar a obtener mucho capital intelectual que posteriormente se traduce en capital monetario.

En cuanto a la información brindada por las gráficas que se generaron, en la primera pregunta podemos notar como la "TIENDA-OFICIAL-EN-LINEA", una tienda de la mayor categoría disponible en ML ("platino") tiene un producto de los más vendidos que a la vez es el más caro de estos, el cual es una "Tablet Lenovo", sin embargo sus competidoras tienen precios mucho más bajos y aun así se dentro de las más vendidas. En el segundo gráfico se divide en dos, la primera parte muestra como la gran mayoria de productos tienen envio gratis, lo cual es un indicativo de que es una característica que se busca ofrecer para que los clientes se sientan más atraído por comprar, la segunda muestra como el 100% de los celulares tienen envío gratis por lo cual este tipo de productos es uno muy apetecido y dados sus precios se ofrece el envío gratis para que sea aún más apetecido. La tercera gráfica nos muestra cómo las marcas tienden a mantener un buen rango de precios para que sea accesible sus productos y a la vez potentes si se tiene el capital, sin embargo, es de resaltar que la marca "Apple" es la que muestra la menor diferencia entre su rango menor de precios y el mayor, por lo cual, el objetivo de esa marca no es ofrecer productos accesibles para todo el público sino vender a mayor precio a menor público ofreciendo otros atractivos. En la cuarta pregunta notamos como los termos dominan los productos de la categoría de deportes con mayor precio y a la vez stock, por lo tanto, se puede decir que no están vendiendo mucho y posiblemente se debería bajar los precios para poder reducir stock. El quinto gráfico muestra los productos con mayor cantidad de calificaciones reacondicionados en electrodomésticos, sin embargo, la data recolectada fue insuficiente para generar conclusiones ya que el producto con más calificaciones es 8, por lo tanto no es concluyente, falta información.

Bibliografía

- Comisión federal de comercio USA. (n.d.). *Servicios de terceros*. Servicios de Terceros |

 Comisión Federal de Comercio. Retrieved September 25, 2024, from

 https://www.ftc.gov/es/pol%C3%ADtica-de-privacidad-y-noticias/pol%C3%ADtica-de-privacidad/servicios-de-terceros
- DataWeave. (2024). *Front page*. DataWeave: E-commerce Analytics for Brands & Retailers.

 Retrieved September 25, 2024, from http://dataweave.com
- Elaboración propia. (2024, September 19). *Diagrama general datawarehouse*. Retrieved

 September 25, 2024, from

 https://drive.google.com/file/d/1jFknEaM3q0UYlfuT1MWdbl3MIqUFOSww/view?u

 sp=sharing
- Equipo editorial de IONOS. (2020, September 10). Web scraping: ¿qué es y para qué se utiliza esta técnica? IONOS. Retrieved September 25, 2024, from https://www.ionos.es/digitalguide/paginas-web/desarrollo-web/que-es-el-web-scrapin g/
- Mercado Libre. (2023, June 29). *Developers*. Developers. Retrieved September 25, 2024, from https://developers.mercadolibre.cl/es_ar/dominios-y-categorias
- Mercado Libre. (2023, December 4). *Developers*. Developers. Retrieved September 25, 2024, from https://developers.mercadolibre.cl/es_ar/pedidos-y-opiniones
- Mercado Libre. (2024). *API Recursos Cross*. Mercado Libre Developers. Retrieved September 25, 2024, from https://developers.mercadolibre.cl/es_ar/envios
- Mercado Libre. (2024). *Developers*. Developers. Retrieved September 25, 2024, from https://developers.mercadolibre.cl/es ar/guia-para-producto
- Mercado Libre. (2024). *Recursos API ML*. API Ítems y Búsquedas. Retrieved Septembre 25, 2024, from https://developers.mercadolibre.cl/es ar/items-y-busquedas

- Mercado Libre. (2024). Somos en Mercado Libre Argentina. Mercado Libre. Retrieved

 September 25, 2024, from

 https://www.mercadolibre.com.ar/institucional/somos#deal_print_id=74856120-7b90
 11ef-9c1c-854f3fdfb45d&c_id=button-normal&c_element_order=1&c_campaign=TR

 ACKING&c_uid=74856120-7b90-11ef-9c1c-854f3fdfb45d
- Mercado Libre. (2024, May 23). *Developers*. Developers. Retrieved September 25, 2024, from https://developers.mercadolibre.cl/es_ar/tendencias
- Richardson, L. (2024, January 17). *Beautiful Soup: We called him Tortoise because he taught*us. Crummy. Retrieved September 25, 2024, from

 https://www.crummy.com/software/BeautifulSoup/#Download
- Scrapy. (2024). *Front Page*. Scrapy | A Fast and Powerful Scraping and Web Crawling Framework. Retrieved September 25, 2024, from https://scrapy.org/
- SimilarWeb. (2024). *Front page*. Similarweb Digital Intelligence: Unlock Your Digital Growth. Retrieved September 25, 2024, from http://similarweb.com
- Similarweb LTD. (2024). *About Us* | *Our Mission, Company, and History*. Similarweb. Retrieved September 25, 2024, from https://www.similarweb.com/corp/about/
- Software Freedom Conservancy. (2024). *Front Page*. Selenium. Retrieved September 25, 2024, from https://www.selenium.dev/